relat_chen

November 4, 2019

1 Projeto 3 - Supercomputação

1.0.1 Lucas Chen Alba

1.1 Descrição do problema

Este projeto consiste em realizar simulações do conhecido problema do caxeiro-viajante (https://en.wikipedia.org/wiki/Travelling_salesman_problem) e analisar o ganho de velocidade com a utilização de técnicas de computação paralela e otimizações. A simulação consiste em encontrar o caminho ótimo ou sub-ótimo para um dado número de nós na rede do caxeiro. A técnica usada é a de montar sequências aleatórias e selecionar a melhor dentre elas

1.2 Medições de tempo

Para as medições do tempo gasto nas simulações foi utilizada a biblioteca *chrono* para CPU e a biblioteca nativa do CUDA para GPU.

A simulação utiliza-se de duas configurações de *flags* de compilação distintas:
-O3 (para GPU)
-O3 -fopenmp (para CPU)

1.3 Organização geral do código

1.3.1 Local Search

Para a otimização discreta "Local Search" foram implementadas duas novas funções: **void local_search(std::vector<std::vector> points, double &best_cost, std::vector<std::vector> &best_sol)**: Esta função irá receber um caminho aleatório e irá otimizá-lo até chegar em uma solução sub-ótima, significando um mínimo local. Ela faz isso a partir da checagem de "cruzamentos" entre dois pares de pontos quaisquer do caminho, ela então realiza um "swap" dos pontos, assim, quando todos os cruzamentos forem resolvidos, este será o mínimo local. **bool check_intersec(std::vector p1, std::vector p2, std::vector q1, std::vector q2)**: Esta função recebe uma sequência de 4 pontos e checa se há alguma interseção entre os segmentos de reta formados pelos dois pares de pontos.

Na função *main()* serão gerados N caminhos aleatórios, caminhos estes que serão passados para chamadas da funçãoeste número define a quantidade de caminhos iniciais aleatórios seráo otimizados pelo Local Search

1.3.2 GPU (CUDA)

Este código realiza a divisão de tarefas em "kernels", assim, cada kernel realiza um "shuffle" nos caminhos, guardando a respectiva sequência e a distância total em vetores **device** (memória global da GPU). Assim, conseguimos utilizar a função da biblioteca thrust (thrust::min_element) para localizar o índice do menos caminho.

```
In [5]: import pandas as pd
        import matplotlib.pyplot as plt

In [6]: # Mean times
        groups = [[17.82, 0.010]]
        group_labels = ['1']

        # Convert data to pandas DataFrame.
        df = pd.DataFrame(groups, index=group_labels).T

        # Plot
        pd.concat(
            [df.loc[0].rename('Local Search'),
             df.loc[1].rename('GPU')],
            axis=1).plot.bar()
        plt.xlabel('Times simulated', fontsize=13)
        plt.ylabel('Time(s)', fontsize=13)
        plt.title('Simulation times', fontsize=16)

Out[6]: Text(0.5, 1.0, 'Simulation times')
```

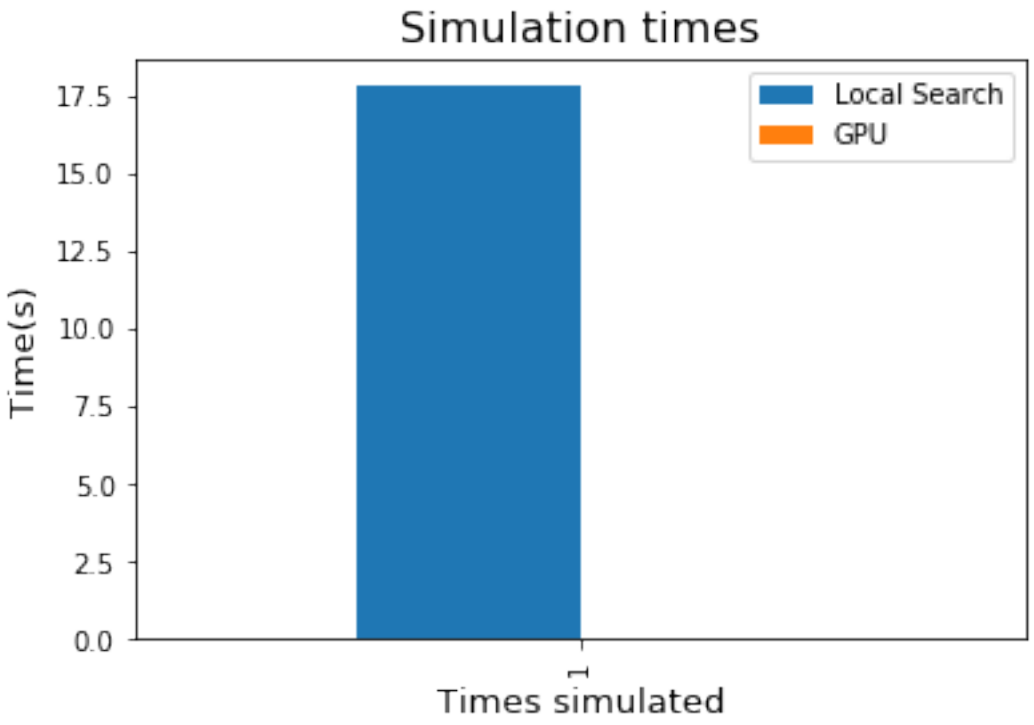

1.4 Resultados e análises

Percebemos um alto ganho no desempenho quando comparamos a versão CPU com a GPU. Isso se deve ao fato da GPU possuir muitos kernels que realizam as terefas simultaneamente, enquante na CPU (Local Search) cada task realiza também as tarefas em paralelo, porém é necessário um bloco de código inserido em uma região crítica (#pragma omp critical), para evitar escritas simultâneas na memória.

```
In [ ]:
```